



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE XXXXXXXXX
DEPARTAMENTO DE XXXXXXXXXX
CURSO DE GRADUAÇÃO EM ENGENHARIA MECÂNICA

PAULO CESAR DA SILVA JUNIOR

**CONTRIBUIÇÕES PARA O ENTENDIMENTO DA INFLUÊNCIA DE VARIÁVEIS NA
VIBRAÇÃO DE MOINHOS DE ROLOS VERTICAIS, NO PROCESSO DE MOAGEM
DO CIMENTO COM AUXÍLIO DE MACHINE LEARNING.**

FORTALEZA

2024

PAULO CESAR DA SILVA JUNIOR

CONTRIBUIÇÕES PARA O ENTENDIMENTO DA INFLUÊNCIA DE VARIÁVEIS NA
VIBRAÇÃO DE MOINHOS DE ROLOS VERTICAIS, NO PROCESSO DE MOAGEM DO
CIMENTO COM AUXÍLIO DE MACHINE LEARNING.

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Engenharia mecânica
do Centro de XXXXXXXX da Universidade
Federal do Ceará, como requisito parcial à
obtenção do grau de bacharel em Engenharia
mecânica.

Orientador: Profa. Dra. Rosineide Fer-
nando da Paz

FORTALEZA

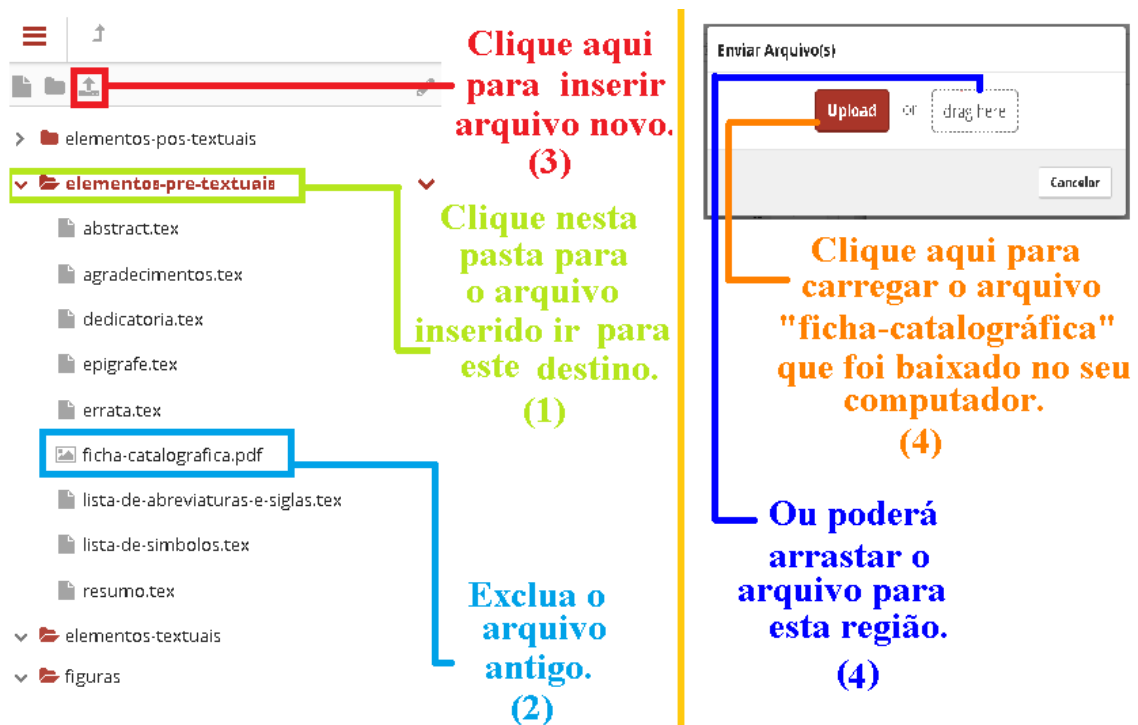
2024

Para criar sua ficha catalográfica, preencha corretamente o Módulo de Elaboração de Fichas Catalográficas (CATALOG!) disponibilizado no link:

<http://fichacatalografica.ufc.br/>

Em seguida, deve-se renomear o arquivo gerado como “ficha-catalografica” e adicioná-lo ao *template* na pasta “elementos-pre-textuais”. É necessário, contudo, excluir o antigo arquivo “ficha-catalografica” antes de adicionar o novo.

A figura a seguir mostra os passos enumerados para a inclusão da ficha catalográfica no *ShareLatex*.



PAULO CESAR DA SILVA JUNIOR

CONTRIBUIÇÕES PARA O ENTENDIMENTO DA INFLUÊNCIA DE VARIÁVEIS NA
VIBRAÇÃO DE MOINHOS DE ROLOS VERTICAIS, NO PROCESSO DE MOAGEM DO
CIMENTO COM AUXÍLIO DE MACHINE LEARNING.

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Engenharia mecânica
do Centro de XXXXXXXX da Universidade
Federal do Ceará, como requisito parcial à
obtenção do grau de bacharel em Engenharia
mecânica.

Aprovada em:

BANCA EXAMINADORA

Profa. Dra. Rosineide Fernando da Paz (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. XXXXXXXX XXXXXXXX XXXXXXXX
Universidade do Membro da Banca Dois (SIGLA)

Prof. Dr. XXXXXXXX XXXXXXXX XXXXXXXX
Universidade do Membro da Banca Três (SIGLA)

Prof. Dr. XXXXXXXX XXXXXXXX XXXXXXXX
Universidade do Membro da Banca Quatro (SIGLA)

À minha família, por sua capacidade de acreditar em mim e investir em mim. Mãe, seu cuidado e dedicação foi que deram, em alguns momentos, a esperança para seguir. Pai, sua presença significou segurança e certeza de que não estou sozinho nessa caminhada.

AGRADECIMENTOS

Ao Prof. Dr. Ricardo Silva Thé Pontes por me orientar em minha tese de doutorado.

Ao Prof. Dr. Tobias Rafael Fernandes Neto, coordenador do Laboratório de Sistemas Motrizes (LAMOTRIZ) onde este *template* foi desenvolvido.

Ao Doutorando em Engenharia Elétrica, Ednardo Moreira Rodrigues, e seu assistente, Alan Batista de Oliveira, aluno de graduação em Engenharia Elétrica, pela adequação do *template* utilizado neste trabalho para que o mesmo ficasse de acordo com as normas da biblioteca da Universidade Federal do Ceará (UFC).

Aos bibliotecários da Universidade Federal do Ceará: Francisco Edvander Pires Santos, Juliana Soares Lima, Izabel Lima dos Santos, Kalline Yasmin Soares Feitosa e Eliene Maria Vieira de Moura, pela revisão e discussão da formatação utilizada neste *template*.

Ao aluno Thiago Nascimento do curso de ciência da computação da Universidade Estadual do Ceará que elaborou o *template* do qual este trabalho foi adaptado para Universidade Federal do Ceará.

Ao Prof. Dr. Humberto de Andrade Carmona do Curso de Física da UFC pelo primeiro incentivo para o uso do \LaTeX .

Ao aluno de graduação em engenharia elétrica e amigo, Lohan Costa por me apresentar a plataforma *ShareLatex* que depois migrou para a plataforma *OverLeaf*.

Aos amigos de laboratório, Felipe Bandeira, Renan Barroso e Roney Coelho, pelas discussões sobre os recursos do \LaTeX .

Aos meus pais, irmãos e sobrinhos, que nos momentos de minha ausência dedicados ao estudo superior, sempre fizeram entender que o futuro é feito a partir da constante dedicação no presente!

Agradeço a todos os professores por me proporcionar o conhecimento não apenas racional, mas a manifestação do caráter e afetividade da educação no processo de formação profissional, por tanto que se dedicaram a mim, não somente por terem me ensinado, mas por terem me feito aprender.

E à Fundação Cearense de Apoio ao Desenvolvimento (Funcap), na pessoa do Presidente Tarcísio Haroldo Cavalcante Pequeno pelo financiamento da pesquisa de doutorado via bolsa de estudos.

“O sonho é que leva a gente para frente. Se a gente for seguir a razão, fica aquietado, acomodado.”

(Ariano Suassuna)

RESUMO

Em *Pelas Ondas do Rádio: Cultura Popular, Camponeses e o MEB* analisa a participação de camponeses do nordeste brasileiro no Movimento de Educação de Base. A perspectiva da tese é a de demonstrar como os trabalhadores envolvidos com as escolas radiofônicas elaboraram ações para manutenção e reprodução da escola em sua comunidade, visando obter os benefícios necessários à reprodução e melhoria de seu modo de vida. A partir de representações políticas e culturais singulares, dentre as quais vigoraram: um sentido para escola, um papel para o sindicato e para participação política, preceitos do direito de uso da terra e dos direitos do trabalho, assim como, sentidos múltiplos para o uso do rádio como meio de comunicação, informação e lazer, os camponeses do MEB, foram coadjuvantes da proposição católica modernizadora de inícios de 1960. Isto posto, demarca que a ação do camponês nordestino e seu engajamento político, seja no MEB, nos sindicatos rurais, nas Juventudes Agrárias Católicas (JAC's), no MCP, e nas mais diversas instâncias dos movimentos sociais do período, não se apartaram do processo modernizador. Neste sentido, considera-se que a modernização brasileira foi pauta das instituições, organismos políticos e partidos, assim como, do movimento social, instância em que ela foi ressignificada a partir de elementos da vida material, que envolviam diretamente, no momento em questão, a problemática do direito a terra, do direito a educação e cultura e dos direitos do trabalho.

Palavras-chave: Camponeses. Cultura popular. Educação de adultos. Escola rural.

ABSTRACT

In this on the radio waves: popular culture, peasants and the Basic Education Movement we analyze the participation of peasants of the Brazilian northeastern region in the Basic Education Movement. The focus of this thesis is to demonstrate how the labors involved with broadcast schools have elaborated actions for maintaining and spreading the schools in their communities, in order to achieve the necessary means to improve their way of life. Peasants of the Basic Education Movement have been coadjuvant of the modernizing catholic proposition of the early 1960s, by means of quite peculiar political and cultural representations. Some of these representations were: a meaning for the school, a role for the union and for the political participation, precepts of the land use rights and labor rights, and the multiple meanings of the radio as a mass communication, information and leisure medium. This study intends to stress that the actions – and the political enrollment – of the northeastern peasant could not ever be separated from the modernizing process. The connection can be observed in different social movements of the period, such as the Basic Education Movement, rural unions, the Catholic Agrarian Youth and the MCP. In this sense, we consider that, if the Brazilian modernization was a guideline for the institutions, political organisms and parties for the social movement, such a modernization was a guideline of demands based on elements of material life. Those elements included, by that time, the agrarian reform, the educational issue and labor urgencies.

Keywords: Adult education. Community schools. Peasants. Popular culture.

LISTA DE FIGURAS

Figura 1 – Gráfico de dispersão com relação linear.	28
Figura 2 – Gráfico de dispersão com relação exponencial.	28
Figura 3 – Esquema representativo de uma floresta aleatória.	29
Figura 4 – Diagrama simplificado de um neurônio humano. 1—dendritos, local de entrada de sinal, 2—núcleo do neurônio, 3—zona de iniciação (onde o potencial de ação do neurônio é formado), 4—axônio, e 5—terminações axonais (que formam conexões com outras células e são os locais de saída de sinal), respectivamente.	31
Figura 5 – Diagrama simplificado de um neurônio matemático. 1—entradas de sinal, 2—pesos, 3—somador, 4—ativador (função de ativação), e 5—saída de sinal, respectivamente.	31
Figura 6 – Diagrama simplificado da operação de uma rede neural.	32
Figura 7 – Estrutura de uma rede neural LSTM.	33
Figura 8 – Gráfico de tensão considerando a impedância humana	38
Figura 9 – Produção anual das dissertações de mestrado e teses de doutorado entre os anos de 1990 e 2008	39

LISTA DE TABELAS

Tabela 1 – Notas dos participantes nas avaliações A, B e C	39
--	----

LISTA DE SÍMBOLOS

A_e	Área efetiva da antena
B	Largura de faixa em que o ruído é medido em Hertz
d	Distância em metros
E	Campo elétrico
FA	Fator da antena
Gr	Ganho de recepção
h	Altura efetiva ou comprimento efetivo de uma antena
I	Corrente elétrica
k	Constante de Boltzmann's
K	Eficiência de irradiação
M	Variação do patamar de ruído em função da RBW
N	Condutor de neutro
NF	Figura de ruído
N_i	Potência do ruído na entrada
N_o	Potência do ruído na saída
P	Potência
R	Resistência
S_i	Potência do sinal na entrada
S_o	Potência do sinal na saída
t	Tempo
V	Tensão
Z_L	Impedância da antena
Z_o	Impedância de referência (50Ω)
λ	Comprimento de onda
Γ	Coefficiente de reflexão

SUMÁRIO

1	INTRODUÇÃO	15
2	FUNDAMENTAÇÃO TEÓRICA	16
2.1	Análise de Vibração em Equipamentos Rotativos	16
2.2	Moinhos de Rolos Verticais: Princípios e Falhas Características	17
2.3	Machine Learning em Manutenção Preditiva	19
2.4	Algoritmos de Machine Learning para Análise de Vibração	20
2.5	Métricas de Avaliação para Modelos Comparativos	22
2.6	Trabalhos Relacionados e Estado da Arte	24
3	METODOLOGIA	27
3.1	Inteligência artificial	27
3.2	Regressão linear	27
3.3	Floresta aleatória	29
3.3.1	<i>Etapas de Implementação de uma floresta aleatória</i>	29
3.3.2	<i>Hiperparâmetros</i>	30
3.4	Redes neurais	30
3.5	Long Short Term Memory (LSTM) Neural Network	33
3.6	Exemplo de alíneas	33
3.7	Usando fórmulas matemáticas	35
3.8	Usando código-fonte	36
3.9	Usando teoremas, proposições, etc	36
3.10	Usando Questões	37
4	RESULTADOS	38
4.1	Resultados do Experimento A	38
4.2	Resultados do Experimento B	39
5	CONCLUSÕES E TRABALHOS FUTUROS	41
6	TRABALHOS RELACIONADOS	42
6.1	Vibration Energy Coupling Behavior of Rolling Mills under Double Disturbance Conditions (WANG <i>et al.</i> , 2023)	42
6.2	Multi-scale reconstruction of rolling mill vibration signal based on fuzzy entropy clustering (WANG <i>et al.</i> , 2024)	43

REFERÊNCIAS	44
APÊNDICES	49
APÊNDICE A–EXEMPLO DE APÊNDICE	49
APÊNDICE B–QUESTIONÁRIO UTILIZADO PARA...	50
APÊNDICE C–CÓDIGOS-FONTES UTILIZADOS PARA...	51
APÊNDICE D–<i>IEEE CEFC 2016</i>	52
ANEXOS	54
ANEXO A–EXEMPLO DE UM ANEXO	54
ANEXO B–EXEMPLO DE UM ANEXO EM PDF	55

1 INTRODUÇÃO

Para começar a utilizar este *template*, siga o tutorial clicando no seguinte *link*: http://www.biblioteca.ufc.br/images/arquivos/instrucoes_modelos/tutorial_sharelatex.pdf

For further references see Something Linky or go to the next url: <http://www.sharelatex.com> or open the next file File.txt

Neste *template*, o autor irá encontrar diversas instruções e exemplos dos recursos do uso do \LaTeX na plataforma *Overleaf*. O \LaTeX foi desenvolvido, inicialmente, na década de 80, por Leslie Lamport e é utilizado amplamente na produção de textos matemáticos e científicos, devido a sua alta qualidade tipográfica (GOOSSENS *et al.*, 1994).

O *Overleaf* é uma plataforma *online* que pode ser acessado por meio de qualquer navegador de internet até mesmo de um *smartphone*. Essa plataforma dispensa a instalação de aplicativos no computador para desenvolver trabalhos em \LaTeX . Também, não é necessário instalar *packages*, ou seja, pacotes que permitem diferentes efeitos na formatação e no visual do trabalho. Todos os *packages* que este *template* utiliza são encontrados *online*.

Apresentam-se, também, neste modelo, algumas orientações de como desenvolver um trabalho acadêmico. Entretanto, este arquivo deve ser editado pelo autor de acordo com o seu trabalho sendo que a formatação já está de acordo com o aceito pela Universidade Federal do Ceará.

A introdução, tem como finalidade, dar ao leitor uma visão concisa do tema investigado, ressaltando-se o assunto de forma delimitada, ou seja, enquadrando-o sob a perspectiva de uma área do conhecimento, de forma que fique evidente sobre o que se está investigando; a justificativa da escolha do tema; os objetivos do trabalho; o objeto de pesquisa que será investigado. Observe que não se divide a introdução em seções, mas a mesma informa como o trabalho ao todo está organizado.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os fundamentos teóricos necessários para compreender a aplicação de modelos de machine learning na predição de vibração em moinhos de rolos verticais. A fundamentação está estruturada de forma a contextualizar os equipamentos estudados, os fenômenos físicos envolvidos, as técnicas de aprendizado de máquina aplicáveis e as métricas utilizadas para comparação de desempenho dos modelos.

2.1 Análise de Vibração em Equipamentos Rotativos

A análise de vibração constitui uma das técnicas fundamentais da manutenção preditiva, permitindo o monitoramento contínuo da condição mecânica de equipamentos rotativos (RAO, 2011). A vibração em máquinas rotativas resulta da interação complexa entre forças desequilibradas, rigidez estrutural, amortecimento do sistema e excitações externas, manifestando-se como movimentos oscilatórios que podem ser medidos e analisados (GIRDHAR; SCHEFFER, 2004).

Em equipamentos industriais, a vibração é caracterizada por sua amplitude, frequência e fase, sendo comumente expressa em unidades de velocidade (mm/s) ou aceleração (m/s^2). A análise espectral da vibração permite identificar componentes específicas relacionadas a diferentes fontes de excitação, como desbalanceamento, desalinhamento, folgas mecânicas, defeitos em rolamentos e problemas de lubrificação (MOBLEY, 2002).

O desbalanceamento representa uma das principais causas de vibração em equipamentos rotativos, ocorrendo quando o centro de massa não coincide com o eixo de rotação. Este fenômeno gera forças centrífugas proporcionais ao quadrado da velocidade angular, resultando em vibração síncrona com a rotação do equipamento (VANCE *et al.*, 2010). O desalinhamento entre eixos conectados produz componentes harmônicas características, particularmente na segunda harmônica da frequência de rotação, e pode acelerar significativamente o desgaste de acoplamentos e rolamentos.

A ressonância mecânica constitui outro aspecto crítico na análise de vibração, ocorrendo quando a frequência de excitação coincide com uma frequência natural do sistema. Nestas condições, pequenas forças podem produzir amplitudes de vibração extremamente elevadas, potencialmente causando danos estruturais graves (INMAN, 2014). A identificação e evitação de condições de ressonância são fundamentais para o projeto e operação segura de equipamentos

rotativos.

Os rolamentos representam componentes críticos em máquinas rotativas, sendo responsáveis por uma parcela significativa das falhas em equipamentos industriais. Defeitos em rolamentos produzem padrões de vibração característicos, com frequências específicas relacionadas à geometria do rolamento e à velocidade de rotação. A análise envelope e técnicas de demodulação são frequentemente empregadas para detecção precoce de defeitos em rolamentos (RANDALL, 2011).

A transmissão de vibração através da estrutura da máquina é influenciada pelas características dinâmicas do sistema, incluindo rigidez, amortecimento e massas envolvidas. Pontos de medição devem ser selecionados estrategicamente para capturar adequadamente os fenômenos de interesse, considerando caminhos de transmissão e frequências de ressonância estrutural (SCHEFFER; GIRDHAR, 2004).

Sistemas de monitoramento contínuo de vibração empregam acelerômetros ou sensores de velocidade instalados permanentemente nos equipamentos, permitindo acompanhamento em tempo real da condição mecânica. Estes sistemas frequentemente incorporam análise automatizada de tendências, detecção de alarmes baseada em limites pré-estabelecidos e capacidades de diagnóstico assistido por algoritmos de reconhecimento de padrões (JARDINE *et al.*, 2006).

A norma ISO 10816 estabelece critérios para avaliação de vibração em máquinas rotativas, definindo zonas de operação baseadas em amplitudes de velocidade de vibração. Zona A representa condição nova ou recém-reparada, Zona B indica operação satisfatória, Zona C sugere operação insatisfatória com necessidade de monitoramento intensivo, e Zona D requer ação corretiva imediata (INTERNATIONAL ORGANIZATION FOR STANDARDIZATION, 2009).

2.2 Moinhos de Rolos Verticais: Princípios e Falhas Características

Os moinhos de rolos verticais constituem equipamentos fundamentais na indústria de processamento mineral, sendo amplamente utilizados na produção de cimento, beneficiamento de minérios e processamento de materiais industriais. Estes equipamentos operam através do princípio de moagem por pressão e cisalhamento, onde material alimentado no centro de uma mesa rotativa é submetido à ação de rolos pressurizados hidráulicamente (AUSTIN *et al.*, 1984).

A configuração típica de um moinho de rolos vertical compreende uma mesa rotativa horizontal, múltiplos rolos de moagem montados em braços articulados, sistema hidráulico de

pressurização, separador de ar interno e sistema de exaustão. A mesa rotativa, acionada por motor elétrico através de redutor, distribui o material alimentado radialmente através da força centrífuga, formando uma camada de material entre a mesa e os rolos (DUDA, 1985).

O processo de moagem ocorre pela combinação de forças de compressão e cisalhamento aplicadas pelos rolos sobre o material depositado na mesa. A pressão hidráulica nos rolos, tipicamente variando entre 5-15 MPa, determina a intensidade da moagem e a finura do produto. O material moído é transportado pelo fluxo de ar ascendente até o separador interno, onde partículas finas são coletadas enquanto material grosso retorna à zona de moagem (LOCHER, 2006).

A estabilidade operacional dos moinhos verticais depende criticamente da manutenção de uma camada uniforme de material na mesa de moagem. Flutuações na alimentação, variações nas características do material ou perturbações no fluxo de ar podem desestabilizar esta camada, resultando em vibrações excessivas e redução da eficiência de moagem (HESSE, 2004).

Falhas características em moinhos de rolos incluem desgaste excessivo das superfícies de moagem, problemas no sistema hidráulico de pressurização, desalinhamento de rolos, desgaste de mancais principais e falhas no sistema de vedação. O desgaste das placas de desgaste na mesa e nos rolos representa a principal causa de paradas programadas, exigindo substituição periódica baseada em critérios de desgaste pré-estabelecidos (TROMANS, 1989).

O sistema hidráulico de pressurização dos rolos constitui componente crítico para operação estável. Falhas em cilindros hidráulicos, vazamentos internos, problemas no acumulador de nitrogênio ou degradação do fluido hidráulico podem resultar em instabilidade na força de moagem, causando vibrações e redução da produtividade (SYSTEMS, 2010).

Vibrações excessivas em moinhos verticais podem originar-se de múltiplas causas: instabilidade da camada de moagem, desbalanceamento da mesa rotativa, problemas nos mancais principais, interferência entre rolos e mesa, ou excitações externas transmitidas através da estrutura de suporte. A identificação precisa da fonte de vibração requer análise sistemática combinando medições de vibração, análise espectral e correlação com parâmetros operacionais (REICHARDT; FINKEN, 2004).

A manutenção preditiva em moinhos verticais emprega monitoramento contínuo de parâmetros operacionais incluindo vibração, temperatura de mancais, pressões hidráulicas, corrente do motor principal e características do produto moído. A integração destes parâmetros através de sistemas de monitoramento avançados permite detecção precoce de anomalias e

otimização das estratégias de manutenção (ENGINEERING, 1993).

2.3 Machine Learning em Manutenção Preditiva

A manutenção preditiva baseada em machine learning representa uma evolução natural dos sistemas tradicionais de monitoramento de condição, oferecendo capacidades avançadas de reconhecimento de padrões, previsão de falhas e otimização de estratégias de manutenção (LEE *et al.*, 2014). A aplicação de técnicas de aprendizado de máquina em dados de monitoramento permite identificar relações complexas entre variáveis operacionais e condição dos equipamentos, frequentemente imperceptíveis através de análise manual tradicional.

Os sistemas de manutenção preditiva tradicionais baseiam-se em análise de limites fixos e tendências de parâmetros individuais, oferecendo capacidade limitada para capturar interações multivariadas complexas. Machine learning supera estas limitações através de algoritmos capazes de processar simultaneamente múltiplas variáveis, identificar padrões não-lineares e adaptar-se automaticamente às características específicas dos equipamentos monitorados (SUSTO *et al.*, 2015).

Algoritmos supervisionados de machine learning requerem dados rotulados para treinamento, onde exemplos de condições normais e anômalas são utilizados para construir modelos de classificação ou regressão. Em aplicações de manutenção preditiva, estes rótulos podem representar condições de falha conhecidas, níveis de degradação ou tempo restante até falha. A qualidade e quantidade dos dados rotulados influenciam diretamente a performance dos modelos desenvolvidos (CARVALHO *et al.*, 2019).

Técnicas de aprendizado não-supervisionado são particularmente valiosas quando dados rotulados são escassos, permitindo detecção de anomalias baseada exclusivamente em padrões de operação normal. Algoritmos como clustering, análise de componentes principais e autoencoders podem identificar condições operacionais atípicas sem necessidade de exemplos prévios de falhas (ZHAO *et al.*, 2019b).

O processamento de dados temporais em manutenção preditiva apresenta desafios específicos relacionados à natureza sequencial das observações. Séries temporais de sensores contêm informações sobre tendências de degradação, padrões sazonais e correlações temporais que devem ser adequadamente capturadas pelos algoritmos de machine learning. Técnicas de feature engineering temporal, incluindo estatísticas móveis, transformadas espectrais e análise de autocorrelação, são frequentemente empregadas para extrair características relevantes dos

dados temporais (WANG *et al.*, 2019).

A seleção de características (feature selection) constitui etapa crítica no desenvolvimento de modelos preditivos, especialmente quando lidando com datasets de alta dimensionalidade comuns em aplicações industriais. Técnicas de seleção baseadas em correlação, importância mutual e métodos embedded permitem identificar subconjuntos de variáveis mais relevantes para predição, reduzindo complexidade computacional e melhorando interpretabilidade dos modelos (GUYON; ELISSEEFF, 2003).

A validação de modelos de machine learning em aplicações de manutenção preditiva deve considerar a natureza temporal dos dados, evitando vazamento de informação futuras (data leakage) durante treinamento. Técnicas de validação cruzada temporal, onde modelos são treinados em períodos passados e testados em períodos futuros, proporcionam estimativas mais realistas da performance em cenários operacionais reais (CERQUEIRA *et al.*, 2020).

A interpretabilidade dos modelos representa aspecto fundamental em aplicações industriais, onde engenheiros de manutenção necessitam compreender os fatores contribuintes para decisões automatizadas. Técnicas de explicabilidade como importância de características, valores SHAP e análise de sensibilidade permitem insights sobre o comportamento dos modelos e facilitam aceitação por parte dos usuários finais (ARRIETA *et al.*, 2020).

Sistemas de machine learning para manutenção preditiva devem incorporar capacidades de atualização incremental, permitindo adaptação contínua às condições operacionais em evolução. Algoritmos de online learning e transfer learning facilitam a incorporação de novos dados sem necessidade de retreinamento completo, mantendo relevância dos modelos ao longo do tempo (KHAMASSI *et al.*, 2018).

A integração de modelos de machine learning em sistemas de manutenção existentes requer consideração cuidadosa de aspectos de latência, confiabilidade e manutenibilidade. Arquiteturas de edge computing permitem processamento local de dados de sensores, reduzindo latência e dependência de conectividade de rede, enquanto sistemas na nuvem oferecem capacidades computacionais superiores para modelos complexos (SHI *et al.*, 2016).

2.4 Algoritmos de Machine Learning para Análise de Vibração

A seleção apropriada de algoritmos de machine learning para análise de vibração depende das características específicas dos dados, objetivos de predição e requisitos operacionais. Diferentes famílias de algoritmos oferecem vantagens particulares para diferentes tipos de

problemas de predição de vibração, desde regressão linear simples até ensemble methods complexos e redes neurais profundas (ZHAO *et al.*, 2019b).

Algoritmos de regressão linear representam a base fundamental para muitas aplicações de predição de vibração, oferecendo interpretabilidade superior e baixo custo computacional. A regressão linear assume relação linear entre variáveis preditoras e variável resposta, sendo particularmente efetiva quando esta suposição é válida. Regularização através de Ridge e Lasso regression permite lidar com multicolinearidade e seleção automática de características, respectivamente (HASTIE *et al.*, 2009).

Árvores de decisão e métodos ensemble baseados em árvores, como Random Forest, oferecem capacidade de capturar relações não-lineares complexas entre variáveis de entrada e vibração. Random Forest combina múltiplas árvores de decisão através de bootstrap aggregating (bagging), reduzindo overfitting e fornecendo estimativas de incerteza através da variabilidade entre árvores individuais. A importância de características calculada pelo Random Forest fornece insights valiosos sobre variáveis mais relevantes para predição de vibração (BREIMAN, 2001).

Gradient boosting methods, incluindo XGBoost, LightGBM e CatBoost, representam estado da arte em muitas aplicações de machine learning estruturado. Estes algoritmos constroem modelos ensemble através de combinação sequencial de modelos fracos, onde cada modelo subsequente foca em corrigir erros dos modelos anteriores. XGBoost incorpora regularização avançada e otimizações computacionais que o tornam particularmente efetivo para dados tabulares típicos de aplicações industriais (CHEN; GUESTRIN, 2016).

Support Vector Machines (SVM) oferecem capacidades robustas para problemas de regressão através do conceito de margin maximization e uso de kernel functions para mapear dados para espaços de dimensionalidade superior. SVM com kernel RBF pode capturar relações não-lineares complexas, sendo particularmente efetivo em cenários com ruído e outliers. No entanto, o alto custo computacional pode limitar aplicabilidade para datasets grandes (VAPNIK, 1998).

K-Nearest Neighbors (KNN) representa algoritmo baseado em instâncias que realiza predições baseando-se em similaridade com observações de treinamento. Para predição de vibração, KNN pode ser efetivo quando padrões locais são mais importantes que tendências globais. A seleção apropriada do número de vizinhos (k) e métricas de distância é crítica para performance do algoritmo (COVER; HART, 1967).

Redes neurais artificiais oferecem capacidade universal de aproximação de funções,

sendo capazes de modelar relações extremamente complexas entre variáveis de entrada e vibração. Arquiteturas feedforward multicamadas são comumente empregadas para problemas de regressão, enquanto redes recorrentes (LSTM, GRU) são particularmente adequadas para dados sequenciais temporais. O treinamento efetivo de redes neurais requer datasets grandes e consideração cuidadosa de hiperparâmetros para evitar overfitting (GOODFELLOW *et al.*, 2016).

Algoritmos robustos como Huber regression são especialmente valiosos em aplicações de vibração onde outliers são comuns devido a condições operacionais atípicas ou ruído de sensores. Huber regression combina propriedades de robustez dos estimadores L1 com eficiência dos estimadores L2, oferecendo performance estável na presença de observações atípicas (HUBER, 1964).

Ensemble methods que combinam previsões de múltiplos algoritmos base podem oferecer performance superior através de redução de variância e bias. Voting regressors combinam previsões através de média simples ou ponderada, enquanto stacking utiliza meta-learners para aprender combinações ótimas. A diversidade entre modelos base é fundamental para efetividade de métodos ensemble (ZHOU, 2012).

A seleção de hiperparâmetros representa aspecto crítico para otimização de performance de algoritmos de machine learning. Técnicas como grid search, random search e otimização Bayesiana permitem exploração sistemática do espaço de hiperparâmetros. Validação cruzada temporal deve ser empregada para evitar overfitting e fornecer estimativas realistas de performance em dados futuros (BERGSTRA; BENGIO, 2012).

Feature engineering específico para dados de vibração inclui extração de características no domínio da frequência através de FFT, análise de envelope para detecção de defeitos em rolamentos, estatísticas de ordem superior para capturar não-gaussianidade, e características temporais como RMS, kurtosis e crest factor. A qualidade das características extraídas influencia diretamente a performance dos algoritmos de machine learning (LEI *et al.*, 2020).

2.5 Métricas de Avaliação para Modelos Comparativos

A avaliação sistemática de modelos de machine learning para predição de vibração requer utilização de métricas apropriadas que capturem diferentes aspectos de performance, incluindo precisão, robustez, calibração e eficiência computacional. A seleção de métricas deve alinhar-se com objetivos específicos da aplicação e considerar custos relativos de diferentes tipos de erros de predição (BOTCHKAREV, 2018).

O coeficiente de determinação (R^2) representa métrica fundamental para avaliação de modelos de regressão, indicando a proporção da variância na variável dependente explicada pelo modelo. R^2 varia entre 0 e 1, onde valores próximos a 1 indicam alta capacidade explicativa. No entanto, R^2 pode ser inflado artificialmente pela inclusão de variáveis irrelevantes, sendo necessário considerar versões ajustadas que penalizam complexidade do modelo (STEEL *et al.*, 2013).

Root Mean Square Error (RMSE) quantifica a magnitude típica dos erros de predição, sendo expressa nas mesmas unidades da variável dependente. RMSE penaliza mais fortemente erros grandes devido ao termo quadrático, sendo particularmente sensível a outliers. Esta métrica é valiosa quando erros grandes são especialmente indesejáveis, como em aplicações de segurança crítica (WILLMOTT; MATSUURA, 2005).

Mean Absolute Error (MAE) representa a magnitude média dos erros de predição, oferecendo interpretação mais direta que RMSE. MAE é menos sensível a outliers, fornecendo estimativa mais robusta da performance típica do modelo. A comparação entre RMSE e MAE pode revelar informações sobre a distribuição dos erros, onde RMSE significativamente maior que MAE indica presença de erros grandes ocasionais (WILLMOTT; MATSUURA, 2005).

Mean Absolute Percentage Error (MAPE) normaliza erros pela magnitude da variável dependente, permitindo comparação entre datasets com diferentes escalas. No entanto, MAPE apresenta limitações quando valores verdadeiros são próximos de zero, podendo resultar em valores infinitos ou instáveis. MAPE é particularmente útil para interpretação de resultados por stakeholders não-técnicos (KIM; KIM, 2016).

A análise de resíduos fornece insights importantes sobre adequação dos modelos através de exame de padrões sistemáticos nos erros de predição. Resíduos homoscedásticos e normalmente distribuídos indicam adequação das suposições do modelo, enquanto padrões sistemáticos podem sugerir necessidade de transformações ou modelos mais complexos. Testes de normalidade como Shapiro-Wilk e análise de heteroscedasticidade são ferramentas valiosas neste contexto (MONTGOMERY, 2012).

Métricas de robustez avaliam estabilidade de performance dos modelos na presença de ruído, outliers ou mudanças nas condições operacionais. Técnicas como cross-validation com diferentes partições, análise de sensibilidade a perturbações nos dados e avaliação em subconjuntos específicos podem revelar vulnerabilidades dos modelos. A robustez é particularmente crítica em aplicações industriais onde condições operacionais podem variar significativamente

(HUBER; RONCHETTI, 2009).

A eficiência computacional engloba tanto tempo de treinamento quanto tempo de inferência dos modelos. Tempo de treinamento é relevante para aplicações que requerem retreinamento frequente, enquanto tempo de inferência é crítico para sistemas de tempo real. Métricas como throughput (predições por segundo) e latência (tempo para uma predição) são particularmente relevantes para deployment em produção (LI *et al.*, 2020).

Métricas de calibração avaliam quão bem as estimativas de incerteza dos modelos correspondem à frequência real de erros. Modelos bem calibrados produzem intervalos de predição que contêm a proporção esperada de observações reais. Diagramas de calibração e estatísticas como Brier score permitem avaliação quantitativa da calibração (GUO *et al.*, 2017).

A análise de overfitting através de comparação entre performance de treinamento e teste é fundamental para avaliação de generalização dos modelos. Diferenças significativas entre estas métricas indicam overfitting, sugerindo necessidade de regularização, redução de complexidade ou aumento da quantidade de dados de treinamento. Learning curves que mostram performance em função do tamanho do dataset podem orientar decisões sobre coleta adicional de dados (DOMINGOS, 2012).

Testes estatísticos de significância, como testes t pareados ou testes não-paramétricos de Wilcoxon, permitem avaliação objetiva de diferenças de performance entre modelos. Estes testes consideram variabilidade estatística nas métricas de performance, fornecendo confiança estatística nas comparações. Correções para múltiplas comparações, como correção de Bonferroni, devem ser aplicadas quando comparando múltiplos modelos simultaneamente (DEMŠAR, 2006).

2.6 Trabalhos Relacionados e Estado da Arte

A aplicação de machine learning para predição de vibração em equipamentos industriais tem sido objeto de crescente interesse na literatura científica, com contribuições significativas abrangendo desde técnicas básicas de regressão até arquiteturas avançadas de deep learning. Esta seção apresenta uma revisão dos principais trabalhos relacionados, destacando metodologias, resultados e limitações identificadas (LEI *et al.*, 2020).

Zhang *et al.* (2018) desenvolveram uma arquitetura de rede neural convolucional (CNN) para classificação de falhas em rolamentos baseada em sinais de vibração. O estudo demonstrou superioridade das CNNs em comparação com métodos tradicionais de extração

manual de características, alcançando acurácia superior a 99% em dataset controlado. Limitações incluem avaliação restrita a condições laboratoriais e falta de validação em dados industriais reais com ruído e variabilidade operacional.

Chen *et al.* (2019) compararam múltiplos algoritmos de machine learning (SVM, Random Forest, Neural Networks) para predição de vibração em turbinas eólicas, utilizando dados de 18 meses de operação. Random Forest apresentou melhor performance ($R^2 = 0.87$), superando SVM ($R^2 = 0.82$) e redes neurais ($R^2 = 0.84$). O estudo destacou a importância de feature engineering específico para o domínio, incluindo características espectrais e estatísticas de ordem superior.

Wang *et al.* (2020) propuseram framework integrado combinando análise de componentes principais (PCA) para redução de dimensionalidade com ensemble de algoritmos (Random Forest, XGBoost, Support Vector Regression) para predição de vibração em compressores centrífugos. A abordagem ensemble alcançou RMSE 15% inferior aos modelos individuais, demonstrando benefícios da combinação de algoritmos complementares.

Liu *et al.* (2019) investigaram aplicação de Long Short-Term Memory (LSTM) networks para predição de vibração em mancais de máquinas rotativas, considerando dependências temporais nos dados. A rede LSTM superou modelos tradicionais de regressão ($R^2 = 0.94$ vs 0.78), especialmente em horizontes de predição de médio prazo (30-60 minutos). Limitações incluem alto custo computacional e necessidade de grandes quantidades de dados sequenciais.

Zhao *et al.* (2019a) desenvolveram sistema híbrido combinando Wavelet Transform para pré-processamento de sinais com ensemble de algoritmos (Gradient Boosting, Random Forest, Neural Networks) para diagnóstico de falhas em moinhos de rolos. O sistema alcançou acurácia de 95% na classificação de condições operacionais, superando abordagens tradicionais baseadas em análise espectral manual.

Kumar *et al.* (2020) realizaram estudo comparativo abrangente de algoritmos de machine learning para manutenção preditiva em equipamentos rotativos, avaliando 12 algoritmos diferentes em datasets de 5 tipos de equipamentos. XGBoost e Random Forest emergiram como algoritmos mais consistentes, apresentando boa performance em diferentes tipos de equipamentos e condições operacionais.

Li *et al.* (2018) propuseram arquitetura de deep autoencoder para detecção de anomalias em vibração de equipamentos rotativos, focando em detecção não-supervisionada de condições anômalas. A abordagem demonstrou capacidade de detectar 92% das falhas

incipientes com taxa de falsos positivos inferior a 5%, superando métodos tradicionais baseados em limites fixos.

Ahmed e Nandi (2021) conduziram análise comparativa de técnicas de feature selection para predição de vibração, avaliando métodos baseados em correlação, informação mutual e importância por árvores. Métodos embedded (baseados em Random Forest) apresentaram melhor trade-off entre redução de dimensionalidade e preservação de performance preditiva.

Lacunas identificadas na literatura incluem: (1) limitada validação em dados industriais reais com condições operacionais variáveis; (2) falta de comparações sistemáticas considerando múltiplas métricas de performance e eficiência computacional; (3) inadequada consideração de aspectos de interpretabilidade e explicabilidade dos modelos; (4) insuficiente análise de robustez a ruído e outliers comuns em ambientes industriais (CARVALHO *et al.*, 2019).

O presente trabalho contribui para o estado da arte através de: (1) comparação sistemática de múltiplos algoritmos em dados industriais reais de moinhos de rolos verticais; (2) avaliação abrangente considerando múltiplas métricas de performance, robustez e eficiência; (3) análise detalhada de feature importance e interpretabilidade dos modelos; (4) validação temporal rigorosa evitando data leakage; (5) consideração específica de características operacionais de moinhos verticais na indústria cimenteira (SUSTO *et al.*, 2015).

3 METODOLOGIA

O primeiro passo, que possibilitou o desenvolvimento do trabalho como um todo, foi o recebimento dos dados do processamento de cimento, na fábrica Apodi. (... **falar sobre os dados. Estrutura, colunas, etc...**) (**Falar sobre possíveis tratativas que foram necessárias ser feitas**). Após a realização da curagem dos dados, pudemos partir para uma análise mais aprofundada, a fim de entender com o que estávamos trabalhando, através de uma análise exploratória dos dados. (**Falar sobre técnicas utilizadas na EDA... Mediana, média, boxplot, correlação, desvio padrão, etc...**)

Com o entendimento solidificado acerca do conjunto de dados, o próximo passo foi a aplicação dos modelos empregados que serão responsáveis pela predição do comportamento vibratório dos moinhos de rolos verticais.

3.1 Inteligência artificial


A inteligência artificial (IA) trata-se do campo que se concentra na pesquisa e no avanço de algoritmos que podem compreender e exibir comportamento inteligente, sem a intervenção humana no entendimento ou sem explicitamente dizer como responder a determinados estímulos (DINESH, 2024). Os modelos de IA podem ser vistos nos smartphones, nos carros, nos bancos, nos hospitais, na aplicação da lei, nas organizações de seguros e em muitas outras aplicações (ALI *et al.*, 2023).

3.2 Regressão linear

Nesse trabalho, a base geral de método preditivo aplicado foi a regressão linear. A qual, de acordo com (HESAMIAN *et al.*, 2024), ajuda a identificar e quantificar as relações entre as variáveis, permitindo previsões e compreensão do impacto das variáveis independentes na variável dependente.


Segundo (SCHNEIDER, 2010), a regressão linear é utilizada para estudar a relação linear entre uma variável dependente Y e uma ou mais variáveis independentes X. A variável dependente Y deve ser contínua, enquanto as variáveis independentes podem ser contínuas, binárias ou categóricas. O julgamento inicial de uma possível relação entre duas variáveis contínuas deve sempre ser feito com base em um gráfico de dispersão. Este tipo de gráfico mostrará se a relação é linear (figura 1) ou não linear (figura 2).

Figura 1 – Gráfico de dispersão com relação linear.



Fonte: (SCHNEIDER, 2010).

Figura 2 – Gráfico de dispersão com relação exponencial.



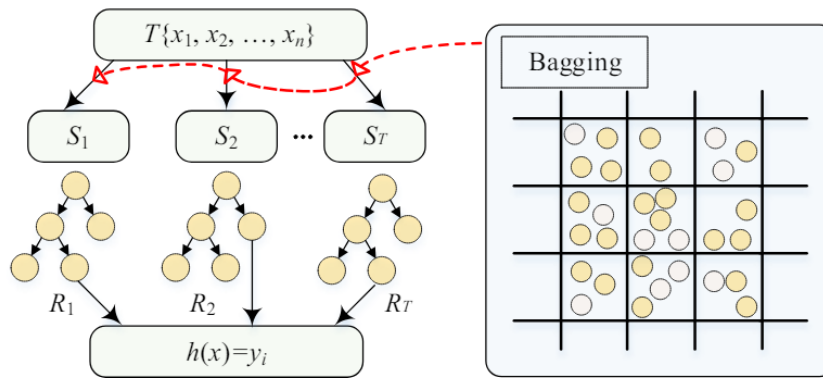
Fonte: (SCHNEIDER, 2010).

Quando temos uma relação linear, podemos dizer que as variáveis são correlacionadas em determinados graus. Porém, correlação não implica causalidade, e deve-se tomar cuidado para não tomar esse único indício como definitivo.

3.3 Floresta aleatória

Falando de modelos de aprendizado de máquina, o primeiro utilizado baseia-se no princípio da floresta aleatória, a qual, de acordo com (WANG *et al.*, 2023), é um método de aprendizado em conjunto que combina múltiplas árvores de decisão, usando *bagging* (amostragem *Bootstrap*) para reamostrar os dados originais e construir novos conjuntos de treinamento. Cada conjunto é usado para construir uma árvore de decisão, e a previsão final é feita pela média das saídas dessas árvores. Floresta aleatória é conhecida por sua escalabilidade e capacidade de lidar com dados de alta dimensão com menos parâmetros de otimização em comparação com outros métodos como Redes Neurais de Retropropagação (BPNN) e Regressão de Vetores de Suporte (SVR). Um esquema representativo de uma floresta aleatória é mostrado na figura 3.

Figura 3 – Esquema representativo de uma floresta aleatória.



Fonte: (WANG *et al.*, 2023).

3.3.1 Etapas de Implementação de uma floresta aleatória

Primeiramente, a amostragem *Bootstrap* é utilizada para reamostrar os dados originais, criando T conjuntos de treinamento rotulados S_1, S_2, \dots, S_T . Esses conjuntos de treinamento são então utilizados para construir árvores de regressão correspondentes R_1, R_2, \dots, R_T . A cada nó, são amostrados aleatoriamente T atributos de M , e o método de divisão ótima é aplicado utilizando o algoritmo CART, construindo o modelo $y = h(x)$. Para amostras de teste desconhecidas, calculam-se os valores previstos $R_1(X), R_2(X), \dots, R_T(X)$ de cada árvore, e a média desses valores é usada como previsão final (WANG *et al.*, 2023).

Devido à amostragem *Bootstrap*, nem todos os dados originais são incluídos nos novos conjuntos de treinamento. Os dados excluídos formam a amostra *Out-of-Bag (OOB)*, que

é utilizada para validação cruzada embutida, avaliando o desempenho das árvores e estimando erros de generalização não tendenciosos (WANG *et al.*, 2023).


3.3.2 Hiperparâmetros

Os principais hiperparâmetros a serem ajustados são a profundidade das árvores e o número de preditores amostrados em cada nó. Árvores profundas tendem a *overfitting*, enquanto árvores rasas podem sofrer de *underfitting*. O número de preditores amostrados em cada nó afeta a precisão da previsão e precisa ser ajustado cuidadosamente para alcançar o melhor modelo (WANG *et al.*, 2023).

3.4 Redes neurais


Segundo (KUFEL *et al.*, 2023), redes neurais artificiais se assemelham ao cérebro humano (Figura 4) e são compostas por múltiplos perceptrons ou ‘neurônios’ que processam e transmitem informações. Para entender seu funcionamento (Figura 5), começamos com a entrada de dados, como imagens, textos ou sons. Esses dados percorrem a rede, sendo processados por camadas sucessivas de neurônios até chegar à saída. Cada camada contém múltiplos neurônios que processam os dados de entrada.

Figura 4 – Diagrama simplificado de um neurônio humano. 1—dendritos, local de entrada de sinal, 2—núcleo do neurônio, 3—zona de iniciação (onde o potencial de ação do neurônio é formado), 4—axônio, e 5—terminações axonais (que formam conexões com outras células e são os locais de saída de sinal), respectivamente.



Fonte: (KUFEL *et al.*, 2023).

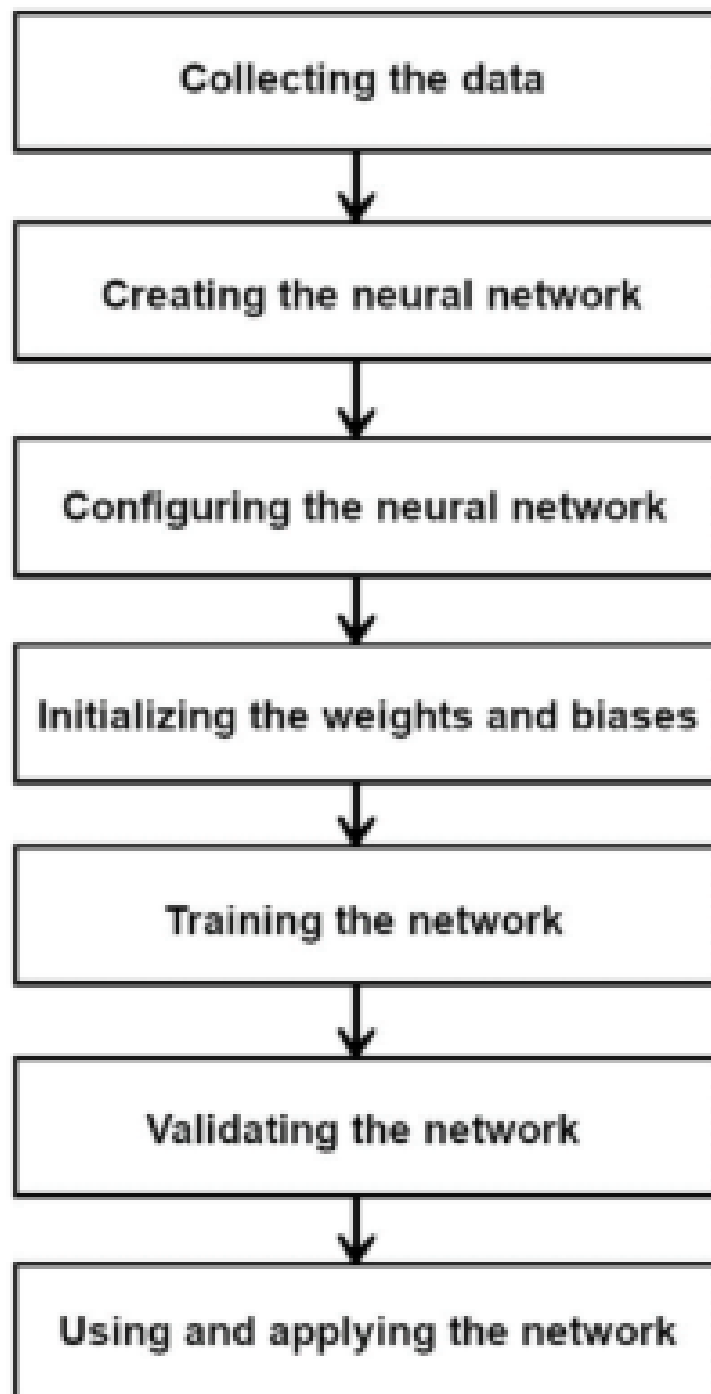
Figura 5 – Diagrama simplificado de um neurônio matemático. 1—entradas de sinal, 2—pesos, 3—somador, 4—ativador (função de ativação), e 5—saída de sinal, respectivamente.



Fonte: (KUFEL *et al.*, 2023).

Para treinar os perceptrons, os pesos são ajustados para minimizar a diferença entre a saída e o sinal esperado. A rede também aprende através do método da maior queda do gradiente, ajustando os comprimentos dos passos na direção oposta. Se o valor alvo em um novo ponto superar o ponto de partida, os passos são reduzidos até que o valor desejado seja alcançado (Figura 6).

Figura 6 – Diagrama simplificado da operação de uma rede neural.



Fonte: (KUFEL *et al.*, 2023).

Texto texto texto texto texto texto texto texto texto texto texto texto texto.

Teorema 3.9.2 (Fermat) *Não existem inteiros $n > 2$, e x, y, z tais que $x^n + y^n = z$*

Texto texto texto texto texto texto texto texto texto texto texto texto texto.

Proposição 3.9.3 *Para demonstrar o Teorema de Pitágoras...*

Texto texto texto texto texto texto texto texto texto texto texto texto texto.

Exemplo 1 *Este é um exemplo do uso do ambiente `exm` definido acima.*

Texto texto texto texto texto texto texto texto texto texto texto texto texto.

Definição 3.9.1 *Definimos o produto de ...*

Texto texto texto texto texto texto texto texto texto texto texto texto texto.

3.10 Usando Questões

Um exemplo de questionário encontra-se no Apêndice B.

5 CONCLUSÕES E TRABALHOS FUTUROS

Parte final do texto na qual se apresentam as conclusões apoiadas no desenvolvimento do assunto. É a recapitulação sintética dos resultados obtidos. Pode apresentar recomendações e sugestões para pesquisas futuras.

6 TRABALHOS RELACIONADOS

Neste capítulo serão apresentados trabalhos que estão conectados a essa pesquisa.

6.1 Vibration Energy Coupling Behavior of Rolling Mills under Double Disturbance Conditions (WANG *et al.*, 2023)

O artigo explora as variáveis que influenciam o processo de vibração em laminadores, destacando a complexidade do comportamento dinâmico sob condições de distúrbio. Os autores identificam variáveis críticas que afetam a energia de vibração e a estabilidade do sistema.

Uma das principais variáveis discutidas é a flutuação da força de laminação. O estudo aponta que as flutuações nas forças aplicadas durante o processo de laminação têm um impacto significativo no fluxo de energia de vibração. Aumentos nas flutuações de força resultam em um aumento correspondente na energia de vibração, indicando que a estabilidade do laminador pode ser comprometida por variações inesperadas nas forças de laminação.

Outra variável importante é o torque de pré-carga. Embora as mudanças no torque de pré-carga não afetem diretamente a amplitude do fluxo de energia de vibração, a interação entre o torque e as flutuações de força pode influenciar a dinâmica do sistema. O estudo sugere que a otimização do torque de pré-carga pode ajudar a controlar as vibrações.

Além disso, o damping (ou amortecimento) do sistema é uma variável crucial. O artigo mostra que, com um coeficiente de amortecimento entre 0,001 e 0,01, a energia de vibração diminui significativamente sob certas frequências de excitação. Quando o coeficiente de amortecimento é aumentado para entre 0,01 e 0,1, a redução da energia de vibração se torna ainda mais pronunciada, indicando que um bom controle do amortecimento pode ser uma estratégia eficaz para mitigar vibrações.

A largura da tira e o módulo da tira também são destacados como variáveis que afetam o comportamento de vibração. O aumento do módulo da tira está associado a um aumento no fluxo de energia de vibração no sistema de acionamento principal, enquanto a variação na largura da tira tem um impacto mais significativo no sistema vertical.

Por fim, o ângulo de fase entre o torque de laminação e as flutuações de torque é identificado como uma variável que apresenta um padrão de "V" no fluxo de energia de vibração, com um mínimo de energia em ângulos de fase específicos. Essa relação complexa entre as variáveis destaca a necessidade de um controle cuidadoso para otimizar o desempenho do

laminador e reduzir as vibrações indesejadas.

6.2 Multi-scale reconstruction of rolling mill vibration signal based on fuzzy entropy clustering (WANG *et al.*, 2024)

O artigo aborda a complexidade das vibrações em moinhos de laminação, enfatizando como diversas variáveis afetam esses sinais. Durante a operação dos moinhos, as vibrações são influenciadas por fatores como condições de trabalho, variações na carga, e a interação entre os componentes mecânicos do equipamento. Essas influências resultam em sinais de vibração que apresentam características não estacionárias, tornando a análise e a previsão desafiadoras.

Os autores destacam que as vibrações verticais são particularmente pronunciadas durante o processo de laminação a frio, o que justifica a coleta de dados focada nesse sentido. O uso do sensor de vibração AC104-1A permite a captura precisa dessas vibrações, mas os sinais coletados ainda são afetados por ruídos e interferências, que podem prejudicar a qualidade das informações obtidas.

Para lidar com esses desafios, o estudo propõe um método de reconstrução de sinais em múltiplas escalas, que combina a entropia fuzzy com o algoritmo de clustering Gath-Geva. Este método visa decompor os sinais de vibração em componentes intrínsecos (IMFs), permitindo uma análise mais detalhada das características de cada componente. A decomposição modal ajuda a isolar as influências específicas que afetam as vibrações, como flutuações na tensão do material, variações na velocidade de operação e desbalanceamentos mecânicos.

Os resultados mostram que a abordagem proposta não apenas melhora a qualidade dos sinais reconstruídos, mas também facilita a identificação das variáveis que impactam as vibrações. A pesquisa conclui que a análise das vibrações em moinhos de laminação, considerando suas características não estacionárias e as variáveis que as afetam, é crucial para o desenvolvimento de modelos preditivos mais precisos, contribuindo para a manutenção eficiente e a operação segura dos equipamentos. Essa metodologia pode ser aplicada para otimizar processos e reduzir falhas, melhorando a confiabilidade dos moinhos.

REFERÊNCIAS

- AHMED, H.; NANDI, A. K. Comparative study of machine learning algorithms for bearing fault diagnosis. **Sensors**, MDPI, v. 21, n. 19, p. 6436, 2021.
- ALI, S.; ABUHMED, T.; EL-SAPPAGH, S.; MUHAMMAD, K.; ALONSO-MORAL, J. M.; CONFALONIERI, R.; GUIDOTTI, R.; Del Ser, J.; DÍAZ-RODRÍGUEZ, N.; HERRERA, F. Explainable artificial intelligence (xai): What we know and what is left to attain trustworthy artificial intelligence. **Information Fusion**, v. 99, p. 101805, 2023. ISSN 1566-2535. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1566253523001148>.
- ARRIETA, A. B.; DÍAZ-RODRÍGUEZ, N.; SER, J. D.; BENNETOT, A.; TABIK, S.; BARBADO, A.; GARCÍA, S.; GIL-LÓPEZ, S.; MOLINA, D.; BENJAMINS, R.; CHATILA, R.; HERRERA, F. Explainable artificial intelligence (xai): Concepts, taxonomies, opportunities and challenges toward responsible ai. **Information Fusion**, Elsevier, v. 58, p. 82–115, 2020.
- AUSTIN, L. G.; KLIMPEL, R. R.; LUCKIE, P. T. **Introduction to the Mathematical Description of Grinding as a Rate Process**. [S. l.]: Powder Technology, 1984. v. 5. 1–17 p.
- BERGSTRA, J.; BENGIO, Y. Random search for hyper-parameter optimization. **Journal of Machine Learning Research**, JMLR, v. 13, p. 281–305, 2012.
- BOTCHKAREV, A. Performance metrics (error measures) in machine learning regression, forecasting and prognostics: Properties and typology. **arXiv preprint arXiv:1809.03006**, 2018.
- BREIMAN, L. Random forests. **Machine Learning**, Springer, v. 45, n. 1, p. 5–32, 2001.
- CARVALHO, T. P.; SOARES, F. A.; VITA, R.; FRANCISCO, R. d. P.; BASTO, J. P.; ALCALÁ, S. G. A systematic literature review of machine learning methods applied to predictive maintenance. **Computers & Industrial Engineering**, Elsevier, v. 137, p. 106024, 2019.
- CERQUEIRA, V.; TORGO, L.; MOZETIČ, I. Evaluating time series forecasting models: An empirical study on performance estimation methods. **Machine Learning**, Springer, v. 109, n. 11, p. 1997–2028, 2020.
- CHEN, C.; LIU, Y.; KUMAR, D.; ZENG, X.; RAHIMI, M.; ONORI, S.; HARLEY, R. G.; HU, L. Machine learning for composite materials. **Annual Review of Materials Research**, Annual Reviews, v. 49, p. 99–129, 2019.
- CHEN, T.; GUESTRIN, C. Xgboost: A scalable tree boosting system. In: **ACM. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [S. l.], 2016. p. 785–794.
- COVER, T.; HART, P. Nearest neighbor pattern classification. **IEEE Transactions on Information Theory**, IEEE, v. 13, n. 1, p. 21–27, 1967.
- DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. **Journal of Machine Learning Research**, JMLR, v. 7, p. 1–30, 2006.
- DINESH, V. R. K. Artificial intelligence; mutating dentistryof the modern eravenkata. The Metascience, 2024.
- DOMINGOS, P. A few useful things to know about machine learning. **Communications of the ACM**, ACM, v. 55, n. 10, p. 78–87, 2012.

DUDA, W. H. **Cement-Data-Book**. London: Macdonald and Evans, 1985. ISBN 978-0-7121-0329-6.

ENGINEERING, H. **Mill Operation and Maintenance Manual**. Switzerland, 1993.

GIRDHAR, P.; SCHEFFER, C. **Practical Machinery Vibration Analysis and Predictive Maintenance**. Oxford: Newnes, 2004. ISBN 978-0-7506-6275-8.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. Cambridge: MIT Press, 2016. ISBN 978-0-262-03561-3.

GOOSSENS, M.; MITTELBACH, F.; SAMARIN, A.; SOUIDI, E. M. **The LATEX companion**. Massachusetts: Addison-Wesley Reading, 1994. v. 2.

GUO, C.; PLEISS, G.; SUN, Y.; WEINBERGER, K. Q. On calibration of modern neural networks. In: PMLR. **International Conference on Machine Learning**. [S. l.], 2017. p. 1321–1330.

GUYON, I.; ELISSEEFF, A. **An Introduction to Variable and Feature Selection**. [S. l.]: JMLR, 2003. v. 3. 1157–1182 p.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2nd. ed. New York: Springer, 2009. ISBN 978-0-387-84857-0.

HESAMIAN, G.; TORKIAN, F.; JOHANNSEN, A.; CHUKHROVA, N. A learning system-based soft multiple linear regression model. **Intelligent Systems with Applications**, v. 22, p. 200378, 2024. ISSN 2667-3053. Disponível em: <https://www.sciencedirect.com/science/article/pii/S266730532400053X>.

HESSE, C. **Process Engineering in the Cement Industry**. Renningen: Expert Verlag, 2004. ISBN 978-3-8169-2353-4.

HUBER, P. J. Robust estimation of a location parameter. **The Annals of Mathematical Statistics**, Institute of Mathematical Statistics, v. 35, n. 1, p. 73–101, 1964.

HUBER, P. J.; RONCHETTI, E. M. **Robust Statistics**. 2nd. ed. Hoboken: Wiley, 2009. ISBN 978-0-470-12990-6.

INMAN, D. J. **Engineering Vibration**. 4th. ed. Boston: Pearson, 2014. ISBN 978-0-13-287169-3.

INTERNATIONAL ORGANIZATION FOR STANDARDIZATION. **ISO 10816-1: Mechanical vibration – Evaluation of machine vibration by measurements on non-rotating parts – Part 1: General guidelines**. Geneva, 2009.

JARDINE, A. K.; LIN, D.; BANJEVIC, D. A review on machinery diagnostics and prognostics implementing condition-based maintenance. **Mechanical Systems and Signal Processing**, Elsevier, v. 20, n. 7, p. 1483–1510, 2006.

KHAMASSI, I.; SAYED-MOUCHAWEH, M.; HAMMAMI, M.; GHÉDIRA, K. Discussion and review on evolving data streams and concept drift adapting. **Evolving Systems**, Springer, v. 9, n. 1, p. 1–23, 2018.

KIM, S.; KIM, H. A new metric of absolute percentage error for intermittent demand forecasts. **International Journal of Forecasting**, Elsevier, v. 32, n. 3, p. 669–679, 2016.

KUFEL, J.; BARGIEŁ-ŁACZEK, K.; KOCOT, S.; KOŹLIK, M.; BARTNIKOWSKA, W.; JANIK, M.; CZOGALIK, Ł.; DUDEK, P.; MAGIERA, M.; LIS, A.; PASZKIEWICZ, I.; NAWRAT, Z.; CEBULA, M.; GRUSZCZYŃSKA, K. What is machine learning, artificial neural networks and deep learning?—examples of practical applications in medicine. **Diagnostics**, v. 13, n. 15, 2023. ISSN 2075-4418. Disponível em: <https://www.mdpi.com/2075-4418/13/15/2582>.

KUMAR, A.; GANDHI, C.; ZHOU, Y.; KUMAR, R.; XIANG, J. Machine learning techniques for predictive maintenance in industrial applications: A comprehensive review. **Journal of Manufacturing Systems**, Elsevier, v. 56, p. 32–45, 2020.

LEE, J.; WU, F.; ZHAO, W.; GHAFFARI, M.; LIAO, L.; SIEGEL, D. Prognostics and health management design for rotary machinery systems—reviews, methodology and applications. **Mechanical Systems and Signal Processing**, Elsevier, v. 42, n. 1-2, p. 314–334, 2014.

LEI, Y.; YANG, B.; JIANG, X.; JIA, F.; LI, N.; NANDI, A. K. Applications of machine learning to machine fault diagnosis: A review and roadmap. **Mechanical Systems and Signal Processing**, Elsevier, v. 138, p. 106587, 2020.

LI, C.; SANCHEZ, R.-V.; ZURITA, G.; CERRADA, M.; CABRERA, D.; VÁSQUEZ, R. E. Fault diagnosis of rotating machinery using knowledge-based fuzzy neural network. **Applied Acoustics**, Elsevier, v. 127, p. 121–129, 2018.

LI, T.; SAHU, A. K.; TALWALKAR, A.; SMITH, V. Federated learning: Challenges, methods, and future directions. **IEEE Signal Processing Magazine**, IEEE, v. 37, n. 3, p. 50–60, 2020.

LIU, R.; YANG, B.; ZIO, E.; CHEN, X. Vibration-based fault diagnosis using machine learning techniques. **Journal of Sound and Vibration**, Elsevier, v. 442, p. 278–294, 2019.

LOCHER, F. W. **Cement: Principles of Production and Use**. Düsseldorf: Verlag Bau+Technik, 2006. ISBN 978-3-7640-0420-0.

MOBLEY, R. K. **An Introduction to Predictive Maintenance**. 2nd. ed. Boston: Butterworth-Heinemann, 2002. ISBN 978-0-7506-7531-4.

MONTGOMERY, D. C. **Introduction to Statistical Quality Control**. 7th. ed. New York: Wiley, 2012. ISBN 978-1-118-14681-1.

RANDALL, R. B. **Rolling Element Bearing Diagnostics—A Tutorial**. [S. l.]: Elsevier, 2011. v. 25. 485–520 p.

RAO, S. S. **Mechanical Vibrations**. 5th. ed. Boston: Pearson, 2011. ISBN 978-0-13-212819-3.

REICHARDT, T.; FINKEN, E. **Vertical Roller Mill Design and Operation**. [S. l.]: Cement Industry Technical Conference, 2004. 93–105 p.

SCHEFFER, C.; GIRDHAR, P. **Machinery Vibration Analysis and Predictive Maintenance**. Oxford: Newnes, 2004. ISBN 978-0-7506-6275-8.

SCHNEIDER, A. e. a. Linear regression analysis: part 14 of a series on evaluation of scientific publications. *Deutsches Arzteblatt international*, 2010.

SHI, W.; CAO, J.; ZHANG, Q.; LI, Y.; XU, L. Edge computing: Vision and challenges. **IEEE Internet of Things Journal**, IEEE, v. 3, n. 5, p. 637–646, 2016.

STEEL, R. G.; TORRIE, J. H.; DICKEY, D. A. **Principles and Procedures of Statistics: A Biometrical Approach**. 3rd. ed. New York: McGraw-Hill, 2013. ISBN 978-0-07-061028-6.

SUSTO, G. A.; SCHIRRU, A.; PAMPURI, S.; MCLOONE, S.; BEGHI, A. Machine learning for predictive maintenance: A multiple classifier approach. **IEEE Transactions on Industrial Informatics**, IEEE, v. 11, n. 3, p. 812–820, 2015.

SYSTEMS, I. D. Gearless mill drive systems. **Cement Industry Technical Conference**, IEEE, p. 1–15, 2010.

TROMANS, D. Mill liner design and application. **Mining Engineering**, Society for Mining, Metallurgy & Exploration, v. 41, n. 12, p. 1363–1372, 1989.

VANCE, J. M.; ZEIDAN, F. Y.; MURPHY, B. **Rotordynamics of Turbomachinery**. Hoboken: John Wiley & Sons, 2010. ISBN 978-0-470-39466-9.

VAPNIK, V. N. **Statistical Learning Theory**. New York: Wiley, 1998. ISBN 978-0-471-03003-4.

WANG, G.; LYU, Z.; LI, X. An optimized random forest regression model for li-ion battery prognostics and health management. **Batteries**, v. 9, n. 6, 2023. ISSN 2313-0105. Disponível em: <https://www.mdpi.com/2313-0105/9/6/332>.

WANG, J.; MA, Y.; ZHANG, L.; GAO, R. X.; WU, D. Deep learning for smart manufacturing: Methods and applications. **Journal of Manufacturing Systems**, Elsevier, v. 48, p. 144–156, 2019.

WANG, K.-Y.; SHARMA, V. S.; ZHANG, G. Predictive maintenance based on machine learning for multi-stage manufacturing processes. **Computers in Industry**, Elsevier, v. 116, p. 103239, 2020.

WANG, L.; WANG, S.; JIA, X.; WANG, X.; YAN, X. Vibration energy coupling behavior of rolling mills under double disturbance conditions. **Electronics**, v. 12, n. 4, 2023. ISSN 2079-9292. Disponível em: <https://www.mdpi.com/2079-9292/12/4/1061>.

WANG, Y.; SUN, J.; CHEN, S.; PENG, W.; ZHANG, D. Multi-scale reconstruction of rolling mill vibration signal based on fuzzy entropy clustering. **Vibroengineering Procedia**, JVE International Ltd., v. 54, p. 22–27, abr. 2024. ISSN 2538-8479. Disponível em: <https://doi.org/10.21595/vp.2024.24026>.

WILLMOTT, C. J.; MATSUURA, K. Advantages of the mean absolute error (mae) over the root mean square error (rmse) in assessing average model performance. **Climate Research**, Inter-Research, v. 30, n. 1, p. 79–82, 2005.

YAN, S. **Understanding LSTM and its diagrams**. 2016. Disponível em: <https://blog.mlreview.com/understanding-lstm-and-its-diagrams-37e2f46f1714>. Acesso em: 24 jun. 2024.

ZHANG, W.; YANG, D.; WANG, H. Deep learning for predictive maintenance: A survey. **arXiv preprint arXiv:1901.01074**, 2018.

ZHAO, D.; LI, J.; CHENG, W.; WEN, W. Intelligent fault diagnosis of rolling bearings using deep learning. **Applied Sciences**, MDPI, v. 9, n. 14, p. 2833, 2019.

ZHAO, R.; YAN, R.; CHEN, Z.; MAO, K.; WANG, P.; GAO, R. X. Machine health monitoring using local feature-based gated recurrent unit networks. **IEEE Transactions on Industrial Electronics**, IEEE, v. 65, n. 2, p. 1539–1548, 2019.

ZHOU, Z.-H. Ensemble methods: Foundations and algorithms. CRC Press, Boca Raton, 2012.

APÊNDICE A – EXEMPLO DE APÊNDICE

Um apêndice é um documento elaborado pelo autor, diferentemente do anexo. Geralmente, se coloca como apêndice, questionários, códigos de programação, tabelas que tomariam muito espaço no meio do trabalho. Artigos, resumos ou qualquer publicação relacionada ao trabalho podem ser utilizados como apêndice.

APÊNDICE B – QUESTIONÁRIO UTILIZADO PARA...

Questão 1. Esta é a primeira questão com alguns itens:

- (a) Este é o primeiro item
- (b) Segundo item

Questão 2. Esta é a segunda questão:

- (a) Este é o primeiro item
- (b) Segundo item

Questão 3. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nunc dictum sed tortor nec viverra. consectetur adipiscing elit. Nunc dictum sed tortor nec viverra.

- (a) consectetur
- (b) adipiscing
- (c) Nunc
- (d) dictum

APÊNDICE C – CÓDIGOS-FONTES UTILIZADOS PARA...

Código-fonte 1 – Hello World em C++

```
1 #include <iostream>
2 using namespace std;
3 int main() {
4     cout<<"Hello World!"<<endl;
5     system("pause");
6 }
```

Código-fonte 2 – Hello World em Java

```
1 public class HelloWorld {
2     public static void main(String[] args) {
3         System.out.println("Hello World!");
4     }
5 }
```

APÊNDICE D – IEEE CEFC 2016

Digest submetido ao The 17th Biennial Conference on Eletromagnetic Field Computation, Miami FL - NOV 13-16, 2016, USA.

Lightning Incidence Model Based on the Electric Field Gradient: 3D Electrostatic Analyses

Ednardo M. Rodrigues, Ricardo S. T. Pontes and Tobias R. Fernandes Neto

Federal University of Ceará, Department of Electrical Engineering, Fortaleza CE, BRAZIL
ednardorodrigues@dee.ufc.br

Abstract— The paper deals with the 3D electrostatic analysis of a lightning strike in a hangar and a power transmission line. The lightning incidence model is based on the electric field gradient. Finally, the simulation results are described and discussed.

Index Terms—Lightning, Electrostatic, Finite element.

I. INTRODUCTION

In [1], a 2D electrostatic analysis of a new lightning incidence model based on the electric field gradient (EFG) was presented. Moreover, the simulations results were carried out for a building and a power transmission line and they were compared with the classical electrogeometrical model (EGM), the rolling-sphere technique (RST) and the leader progression model (LPM) [2]. The present paper estimates the trajectory of lightning strikes from the thundercloud to a grounded metal roof of a hangar. Furthermore, the same procedure will be carried out for 500kV power transmission lines.

II. ELECTROSTATIC ANALYSES

A lightning occurs when the electric field is higher than the breakeven field (400kV/m —3MV/m) [2]. This model is based on the electric field gradient described by

$$\vec{E}_L(\vec{r}) \approx \vec{E}_b(\vec{r}) + \lambda_t \nabla E_b(\vec{r}), \quad (1)$$

$\vec{E}_b(\vec{r})$ is the background electric field, which is function of the position \vec{r} and it is generated by the electric potential difference (EPD) between the cloud and the ground. λ_t is the lightning step length (~50m) [3], and $\vec{E}_L(\vec{r})$ is the lightning electric field. More details about Eq. (1) can be found in [1].

A 3D finite element method (FEM) model of a hangar and a power transmission line (TL) were designed by using the electrostatic module. All simulations were carried out within a cubic domain of 250m x 250m x 250m. The upper level of each domain is defined with -12.5MV, while the lower level is the ground. This is equivalent to a real thundercloud with a potential of (-100MV) at 2km of altitude [4].

The dimensions of the hangar are: 8.60m height, 77.37m width and 229.00m length. The aluminum metal roof has 0.7mm thickness and it is grounded. The second simulation is for a TL composed by three phase conductors, equally spaced by 11.5m and positioned at 40.5m above the reference plane. The TLs are protected by two earth wires spaced by 19m over 54.47m of the reference plane.

III. RESULTS

In order to evaluate the 3D model, the software COMSOL Multiphysics® was used in a computer with quad-core processor of 2.6GHz. For the hangar, the simulation time was around 4s. The necessary physical memory for the simulation

was 1.34GB and 5.6GB of virtual memory. The electric field is very intense at the roof (about 80MV/m) and the lightning (cyan lines) strikes the building roof, as shown in Fig. 1a. In summary, it is not necessary to add air terminals, as long the roof is grounded. The simulation time for the TL was around 6 min, using 15GB of physical memory and 32GB of virtual memory. As shown in Fig 1b, the cyan lines strike the earth wires.




Fig. 1. Case of studies: (a) hangar and (b) power transmission line.

IV. CONCLUSIONS

The EFG simulations predicted that the aluminum metal roof is able to protect the hangar against lightning strikes. In the TL simulation, the earth wires have fulfilled the protection for the phase conductors. Finally, the protection zone and the design of lightning protection system can be evaluated by 3D electrostatic analyses, which are closer to the reality than the 2D analyses. However, 3D models are often more complex and require more simulation time.

REFERENCES

- [1] E. M. Rodrigues, *Novel Lightning Incidence Model Based on the Electric Field Gradient: 2D Electrostatic Analyses*. GROUND'2016 & 7th LPE, 2016.
- [2] V. Cooray, *Lightning protection*, The Institution of Engineering and Technology, 2009.
- [3] V.A. Rakov and M. A. Uman, *Lightning: physics and effects*. Cambridge University Press, 2007.
- [4] S. Visacro, *Descargas atmosféricas: Uma Abordagem de Engenharia (Lightning strike: An Engineering approach)*, Artliber, 2005.

ANEXO A – EXEMPLO DE UM ANEXO

Um anexo é um documento que não foi elaborado pelo autor, ou seja, o autor apenas anexa. Anexos podem ser tabelas, mapas, diagramas, *datasheets*, manuais e etc.

ANEXO B – EXEMPLO DE UM ANEXO EM PDF

O autor pode anexar um *Portable Document Format* (PDF), traduzido como formato portátil de documento. Veja o código fonte utilizado para anexar o arquivo “Sikasil.pdf” que foi colocado dentro da pasta “anexos” que por sua vez está dentro da pasta “elementos-pos-textuais”. Tenha muita atenção na hora de especificar o local do arquivo. Recomenda-se não utilizar caracteres especiais para nomear pastas e, principalmente, arquivos.

Pode-se fazer uma descrição sucinta do arquivo anexado.

Sikasil® GS-630

Glazing sealant for structural & non-structural use

Technical Product Data

Chemical base	1-C silicone
Color (CQP ¹ 001-1)	See Product Overview
Cure mechanism	Moisture-curing
Cure type	Neutral
Density (uncured) (CQP 006-4)	1.4 kg/l approx.
Non-sag properties (CQP 061-4 / ISO 7390)	< 2 mm approx.
Application temperature	5 - 40°C (41 - 104°F)
Skin time ² (CQP 019-2)	10 min approx.
Tack-free time ² (CQP 019-1)	60 min approx.
Curing speed (CQP 049-1)	See diagram 1
Shore A-hardness (CQP 023-1 / ISO 868)	32 approx.
Tensile strength (CQP 036-1 / ISO 37)	1.2 N/mm ² approx.
Elongation at break (CQP 036-1 / ISO 37)	480% approx.
Tear propagation resistance (CQP 045-1 / ISO 34)	6 N/mm approx.
100% modulus (CQP 036-1 / ISO 37)	0.6 N/mm ² approx.
Movement accommodation capability (ASTM C 719)	±50%
Thermal resistance (CQP 513-1)	long term
Short term	4 h
	1 h
	180°C (356°F) approx.
	200°C (392°F) approx.
	220°C (428°F) approx.
Service temperature	-40 - 150°C approx. (-40 - 302°F)
Shelf life (storage below 25°C) (CQP 016-1)	15 months

¹⁾ CQP = Corporate Quality Procedure

²⁾ 23°C (73°F) / 50% r.h.

Description

Sikasil® GS-630 is a durable, neutral-curing silicone sealant and adhesive which combines mechanical strength with high elongation. It adheres excellent to a wide range of substrates. Sikasil® GS-630 is manufactured in accordance with ISO 9001 quality assurance system and the responsible care program.

Product Benefits

- Outstanding UV and weathering resistance
- Excellent adhesion to glass, coated glass, metals and plastics
- Fast curing
- Long-term durability
- High movement capability

Areas of Application

Sikasil® GS-630 is a silicone sealant and adhesive designed for sealing, bonding and mending tasks in a wide variety of industrial applications, e. g. structural and nonstructural applications in facades.

This product is suitable for professional experienced users only. Tests with actual substrates and conditions have to be performed to ensure adhesion and material compatibility.



Cure Mechanism

Sikasil® GS-630 cures by reaction with atmospheric moisture. The reaction thus starts at the surface and proceeds to the core of the joint. The curing speed depends on the relative humidity and the temperature (see diagram 1 below). Heating above 50°C to speed-up the vulcanization is not advisable as it may lead to bubble formation. At low temperatures the water content of the air is lower and the curing reaction proceeds more slowly.




Diagram 1: Curing speed 1C-Sikasil®

Application Limits

All Sikasil® WS, FS, SG, IG, WT and other engineering silicone sealants and adhesives are compatible with each other. Sikasil® WS and FS sealants as well as other Sika engineering silicone sealants are compatible with SikaGlaze® IG sealants. All other sealants have to be approved by Sika before using them in combination with Sikasil® GS-630. Where two or more different reactive sealants are used, allow the first to cure completely before applying the next.

Do not use Sikasil® GS-630 on pre-stressed polyacrylate and polycarbonate elements as it may cause environmental stress cracking (crazing).

The compatibility of gaskets, backer rods and other accessory materials with Sikasil® GS-630 must be tested in advance. Joints deeper than 15 mm should be avoided.

The above information is offered for general guidance only. Advice on specific applications will be given on request.

Method of Application

Surface preparation

Surfaces must be clean, dry and free from oil, grease and dust.

Advice on specific applications and surface pretreatment methods is available from the Technical Service Department of Sika Industry.

Application

After suitable joint and substrate preparation, Sikasil® GS-630 is gunned into place. Joints must be properly dimensioned as changes are no longer possible after construction. For optimum performance the joint width should be designed according to the movement capability of the sealant based on the actual expected movement. The minimum joint depth is 6 mm and a width / depth ratio of 2:1 must be respected if used for weatherproofing. For backfilling it is recommended to use closed cell, sealant compatible foam backer rods e.g. high resilience polyethylene foam rod. If joints are too shallow for backing material to be employed, we recommend using a polyethylene tape. This acts as a release film (bond breaker), allowing the joint to move and the silicone to stretch freely.

For more information please contact the Technical Service Department of Sika Industry.

Tooling and finishing

Tooling and finishing must be carried out within the skin time of the adhesive.

When tooling freshly applied Sikasil® GS-630 press the adhesive to the joint flanks to get a good wetting of the bonding surface.

Removal

Uncured Sikasil® GS-630 may be removed from tools and equipment with Sika® Remover-208 or another suitable solvent. Once cured, the material can only be removed mechanically.

Hands and exposed skin should be washed immediately using Sika® Handclean Towel or a suitable industrial hand cleaner and water. Do not use solvents!

Overpainting

Sikasil® GS-630 cannot be over-painted.

Further Information

Copies of the following publications are available on request:

- Material Safety Data Sheet

Packaging Information

Unipack	600 ml
Cartridge	300 ml
Pail	26 kg
Drum	280 kg

Value Bases

All technical data stated in this Product Data Sheet are based on laboratory tests. Actual measured data may vary due to circumstances beyond our control.

Health and Safety Information

For information and advice regarding transportation, handling, storage and disposal of chemical products, users should refer to the actual Material Safety Data Sheets containing physical, ecological, toxicological and other safety-related data.

Legal Notes

The information, and, in particular, the recommendations relating to the application and end-use of Sika products, are given in good faith based on Sika's current knowledge and experience of the products when properly stored, handled and applied under normal conditions in accordance with Sika's recommendations. In practice, the differences in materials, substrates and actual site conditions are such that no warranty in respect of merchantability or of fitness for a particular purpose, nor any liability arising out of any legal relationship whatsoever, can be inferred either from this information, or from any written recommendations, or from any other advice offered. The user of the product must test the product's suitability for the intended application and purpose. Sika reserves the right to change the properties of its products. The proprietary rights of third parties must be observed. All orders are accepted subject to our current terms of sale and delivery. Users must always refer to the most recent issue of the local Product Data Sheet for the product concerned, copies of which will be supplied on request.

Further information available at:

www.sika.ch

www.sika.com

Sika Schweiz AG

Industry

Tüffenwies 16

CH-8048 Zurich

Switzerland

Tel. +41 44 436 40 40

Fax +41 44 436 45 30

